고객을 세그먼테이션하자 [프로젝트] (1)

11-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
SELECT *
FROM velvety-study-473605-t0.modulabs_project.data
LIMIT 10
```

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	2.55	178
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	3.39	178
3	536365	84406B	CREAM CUPID HEARTS COAT H...	8	2010-12-01 08:26:00 UTC	2.75	178
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	3.39	178
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	3.39	178
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	7.65	178
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-01 08:26:00 UTC	4.25	178
8	536366	22633	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	1.85	178
9	536366	22632	HAND WARMER RED POLKA DOT	6	2010-12-01 08:28:00 UTC	1.85	178
10	536367	84879	ASSORTED COLOUR BIRD ORN...	32	2010-12-01 08:34:00 UTC	1.69	130

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
SELECT COUNT(*)
FROM velvety-study-473605-t0.modulabs_project.data
```

행	f0_
1	541909

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
SELECT
  COUNT(InvoiceNo) AS count_InvoiceNo,
  COUNT(StockCode) AS count_StockCode,
  COUNT(Description) AS count_Description,
  COUNT(Quantity) AS count_Quantity,
  COUNT(InvoiceDate) AS count_InvoiceDate,
  COUNT(UnitPrice) AS count_UnitPrice,
  COUNT(CustomerID) AS count_CustomerID,
  COUNT(Country) AS count_Country
FROM velvety-study-473605-t0.modulabs_project.data
```

행	count_InvoiceNo	count_StockCode	count_Description	count_Quantity	count_InvoiceDate	count_UnitPrice	count_CustomerID	count_Country
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**

- **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
SELECT
   'InvoiceNo' AS column_name,
   ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'StockCode' AS column_name,
   ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
  velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'Description' AS column_name,
   ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'Quantity' AS column_name,
   ROUND(SUM(CASE WHEN Quantity IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'InvoiceDate' AS column_name,
   ROUND(SUM(CASE WHEN InvoiceDate IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'UnitPrice' AS column_name,
   ROUND(SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'CustomerID' AS column_name,
   ROUND(SUM(CASE WHEN CustomerID IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
UNION ALL
SELECT
   'Country' AS column_name,
   ROUND(SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) * 100 / COUNT(*), 2) AS missing_percentage
FROM
   velvety-study-473605-t0.modulabs_project.data
```

행	column_name	missing_percenta...
1	UnitPrice	0.0
2	Country	0.0
3	InvoiceDate	0.0
4	CustomerID	24.93
5	Description	0.27
6	Quantity	0.0
7	StockCode	0.0
8	InvoiceNo	0.0

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT DISTINCT Description
FROM velvety-study-473605-t0.modulabs_project.data
WHERE StockCode = '85123A'
```

행	Description
1	?
2	CREAM HANGING HEART T-LIG...
3	WHITE HANGING HEART T-LIG...
4	wrongly marked carton 22804

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
DELETE FROM velvety-study-473605-t0.modulabs_project.data
WHERE CustomerID IS NULL OR Description IS NULL;
```

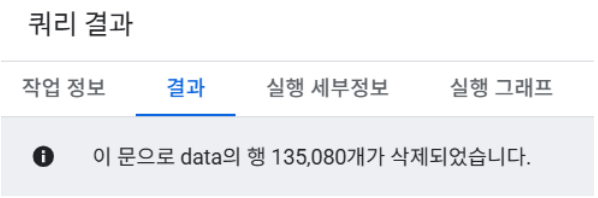

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
SELECT
  COUNT(*) AS num_duplicate_groups
FROM (
  SELECT
    InvoiceNo,
    StockCode,
    Description,
    Quantity,
    InvoiceDate,
    UnitPrice,
    CustomerID,
    Country
  FROM
    velvety-study-473605-t0.modulabs_project.data
  GROUP BY
    InvoiceNo,
    StockCode,
    Description,
```

```
    Quantity,
    InvoiceDate,
    UnitPrice,
    CustomerID,
    Country
HAVING
    COUNT(*) > 1
```

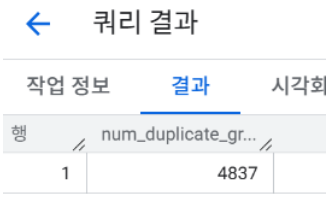

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.data_cleaned AS
SELECT DISTINCT *
FROM velvety-study-473605-t0.modulabs_project.data
WHERE
  CustomerID IS NOT NULL
  AND Description IS NOT NULL;
```

(실행두번눌려서 data_cleaned로나오네요..)

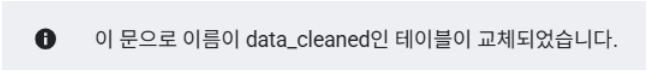

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- **고유(unique)한 InvoiceNo의 개수를 출력하기**

```
SELECT COUNT(DISTINCT InvoiceNo) AS unique_invoice_count
FROM velvety-study-473605-t0.modulabs_project.data_cleaned;
```

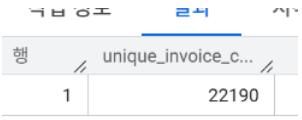

- **고유한 InvoiceNo를 앞에서부터 100개를 출력하기**

```
SELECT DISTINCT InvoiceNo AS unique_invoice
FROM velvety-study-473605-t0.modulabs_project.data_cleaned
LIMIT 100;
```

행	unique_invoice
1	541431
2	C541433
3	537626
4	542237
5	549222
6	556201
7	562032
8	573511
9	581180
10	539318
11	541998

- `InvoiceNo`가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

```
SELECT *
FROM velvety-study-473605-t0.modulabs_project.data_cleaned
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;
```

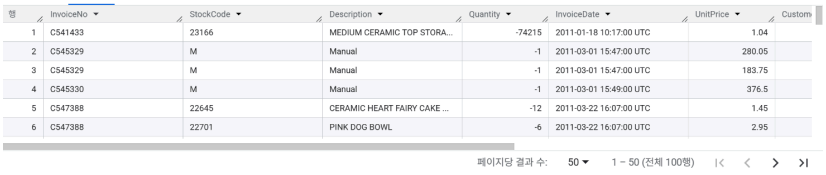

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	Custom
1	C541433	23166	MEDIUM CERAMIC TOP STORA...	-74215	2011-01-18 10:17:00 UTC	1.04	
2	C545329	M	Manual	-1	2011-03-01 15:47:00 UTC	280.05	
3	C545329	M	Manual	-1	2011-03-01 15:47:00 UTC	183.75	
4	C545330	M	Manual	-1	2011-03-01 15:49:00 UTC	376.5	
5	C547388	22645	CERAMIC HEART FAIRY CAKE ...	-12	2011-03-22 16:07:00 UTC	1.45	
6	C547388	22701	PINK DOG BOWL	-6	2011-03-22 16:07:00 UTC	2.95	

페이지당 결과 수: 50 1 – 50 (전체 100행)

- 구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지

```
SELECT ROUND(SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) * 100.0 / COUNT(*),1) AS cancellation_row_rate_percentage
FROM velvety-study-473605-t0.modulabs_project.data_cleaned;
```

행	cancellation_row...
1	2.2

`StockCode` 살펴보기

- 고유한 `StockCode`의 개수를 출력하기

```
SELECT COUNT(DISTINCT StockCode) AS unique_stockCode
FROM velvety-study-473605-t0.modulabs_project.data_cleane
```

행	unique_stockCode
1	3684

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 `StockCode` 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM velvety-study-473605-t0.modulabs_project.data_cleaned
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```

행	StockCode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110
10	23203	1108

- **`StockCode` 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM velvety-study-473605-t0.modulabs_project.data_cleaned
)
WHERE number_count IN (0,1)
```

행	StockCode	number_count
1	POST	0
2	M	0
3	C2	1
4	D	0
5	BANK CHARGES	0
6	PADS	0
7	DOT	0
8	CRUK	0

- **`StockCode` 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**

- **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT
  DISTINCT StockCode,
  number_count
FROM
  (SELECT
     StockCode,
     LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
   FROM
     velvety-study-473605-t0.modulabs_project.data_cleaned
  )
WHERE number_count IN (0, 1);
```

행	outlier_percentage
1	0.48

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM velvety-study-473605-t0.modulabs_project.data_cleaned
WHERE StockCode IN (
  SELECT DISTINCT StockCode
  FROM (SELECT StockCode,LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM velvety-study-473605-t0.modulabs_project.data_cleaned
  )
  WHERE number_count IN (0, 1)
);
```

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 data_cleaned의 행 1,915개가 삭제되었습니다.

Description 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description,COUNT(*) AS description_cnt
FROM velvety-study-473605-t0.modulabs_project.data_cleaned
GROUP BY Description
ORDER BY description_cnt DESC
LIMIT 30;
```

행	Description	description_cnt
1	WHITE HANGING HEART T-LIG...	2058
2	REGENCY CAKESTAND 3 TIER	1894
3	JUMBO BAG RED RETROSPOT	1659
4	PARTY BUNTING	1409
5	ASSORTED COLOUR BIRD ORN...	1405
6	LUNCH BAG RED RETROSPOT	1345
7	SET OF 3 CAKE TINS PANTRY D...	1224
8	LUNCH BAG BLACK SKULL.	1099
9	PACK OF 72 RETROSPOT CAKE ...	1062
10	SPOTTY BUNTING	1026

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM velvety-study-473605-t0.modulabs_project.data_cleaned
WHERE Description IN ('Next Day Carriage', 'High Resolution Image');
```

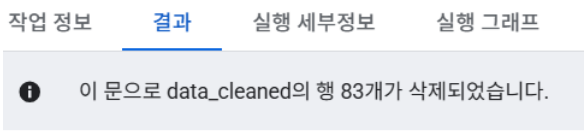

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.data_standardized AS
SELECT
  * EXCEPT (Description),
  UPPER(Description) AS Description
FROM
  velvety-study-473605-t0.modulabs_project.data_cleaned;
```

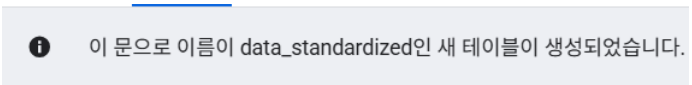

UnitPrice 살펴보기

- `UnitPrice`**의 최솟값, 최댓값, 평균을 구하기**

```
SELECT
  MIN(UnitPrice) AS min_price,
  MAX(UnitPrice) AS max_price,
```

```
  AVG(UnitPrice) AS avg_price
FROM
  velvety-study-473605-t0.modulabs_project.data_standardized;
```

행	min_price	max_price	avg_price
1	0.0	649.5	2.904956757406...

- **단가가 0원인 거래의 개수, 구매 수량(`Quantity`)의 최솟값, 최댓값, 평균 구하기**

```
SESELECT
  COUNT(*) AS cnt_quantity,
  MIN(Quantity) AS min_quantity,
  MAX(Quantity) AS max_quantity,
  AVG(Quantity) AS avg_quantity
FROM
  velvety-study-473605-t0.modulabs_project.data_standardized
WHERE
  UnitPrice = 0;
```

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	cnt_quantity	min_quantity	max_quantity	avg_quantity
1	33	1	12540	420.5151515151...

- `UnitPrice = 0` **를 제거하고 일관된 데이터셋을 유지하기**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.data AS
SELECT *
FROM velvety-study-473605-t0.modulabs_project.data_standardized
WHERE UnitPrice > 0;
```

이 문으로 이름이 data인 테이블이 교체되었습니다.

11-7. RFM 스코어

Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
SELECT DATE(InvoiceDate) AS InvoiceDay,*
FROM velvety-study-473605-t0.modulabs_project.data;
```

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate	UnitPrice	CustomerID
1	2011-01-18	541431	23166	74215	2011-01-18 10:01:00 UTC	1.04	12346
2	2011-01-18	C541433	23166	-74215	2011-01-18 10:17:00 UTC	1.04	12346
3	2010-12-07	537626	85167B	30	2010-12-07 14:57:00 UTC	1.25	12347
4	2010-12-07	537626	22729	4	2010-12-07 14:57:00 UTC	3.75	12347
5	2010-12-07	537626	84997D	6	2010-12-07 14:57:00 UTC	3.75	12347
6	2010-12-07	537626	22771	12	2010-12-07 14:57:00 UTC	1.25	12347

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT
  MAX(DATE(InvoiceDate)) OVER () AS most_recent_date,
  DATE(InvoiceDate) AS InvoiceDay,*
FROM velvety-study-473605-t0.modulabs_project.data;
```

작업 정보 결과 시각화 JSON 실행 세부정보 실행 그래프

행	most_recent_date	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate
1	2011-12-09	2011-10-13	571034	23094	4	2011-10-13 12:47:
2	2011-12-09	2011-08-12	563100	23163	8	2011-08-12 09:57:
3	2011-12-09	2011-05-17	553546	23299	50	2011-05-17 15:42:
4	2011-12-09	2011-11-15	576394	22196	160	2011-11-15 10:32:
5	2011-12-09	2011-02-09	543541	21317	2	2011-02-09 14:44:
6	2011-12-09	2011-02-03	543117	22847	4	2011-02-03 13:30:
7	2011-12-09	2010-12-10	538174	22423	32	2010-12-10 09:35:
8	2011-12-09	2011-03-18	547005	23007	1	2011-03-18 14:20:
9	2011-12-09	2011-11-14	576327	23531	3	2011-11-14 15:19:
10	2011-12-09	2011-11-17	576910	22191	12	2011-11-17 09:51:
11	2011-12-09	2011-09-19	567291	23319	6	2011-09-19 11:55:

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT
   CustomerID,
   MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM velvety-study-473605-t0.modulabs_project.data
GROUP BY CustomerID;
```

행	CustomerID	InvoiceDay
1	12346	2011-01-18
2	12347	2011-12-07
3	12348	2011-09-25
4	12349	2011-11-21
5	12350	2011-02-02
6	12352	2011-11-03
7	12353	2011-05-19
8	12354	2011-04-21
9	12355	2011-05-09
10	12356	2011-11-17
11	12357	2011-11-06

- **가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산하기**

```
SELECT
  CustomerID,
```

```
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM velvety-study-473605-t0.modulabs_project.data
  GROUP BY CustomerID
);
```

행	CustomerID	recency
1	12539	22
2	12579	73
3	12604	79
4	12621	1
5	12625	211
6	12865	26
7	12977	156

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_r AS
SELECT
  CustomerID,
  DATE_DIFF(MAX(InvoiceDay) OVER (), InvoiceDay, DAY) AS Recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM
    velvety-study-473605-t0.modulabs_project.data
  GROUP BY
    CustomerID
);
```

이 문으로 이름이 user_r인 새 테이블이 생성되었습니다.

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS purchase_cnt
FROM
  velvety-study-473605-t0.modulabs_project.data
GROUP BY
  CustomerID;
```

행	CustomerID	purchase_cnt
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8
7	12353	1
8	12354	1
9	12355	1
10	12356	3
11	12357	1

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
  CustomerID,
  SUM(Quantity) AS item_cnt
FROM
  velvety-study-473605-t0.modulabs_project.data
WHERE
  Quantity > 0
GROUP BY
  CustomerID;
```

행	CustomerID	item_cnt
1	12346	74215
2	12347	2458
3	12348	2332
4	12349	630
5	12350	196
6	12352	526
7	12353	20
8	12354	530
9	12355	240

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_rf AS
WITH purchase_cnt AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT InvoiceNo) AS purchase_cnt
  FROM
    velvety-study-473605-t0.modulabs_project.data
  GROUP BY
```

```
    CustomerID
),

item_cnt AS (
  SELECT
    CustomerID,
    SUM(Quantity) AS item_cnt
  FROM
    velvety-study-473605-t0.modulabs_project.data
  WHERE
    Quantity > 0
  GROUP BY
    CustomerID
)

SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.Recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN velvety-study-473605-t0.modulabs_project.user_r AS ur
  ON pc.CustomerID = ur.CustomerID;

SELECT *
FROM velvety-study-473605-t0.modulabs_project.user_rf
```

행	CustomerID	purchase_cnt	item_cnt	Recency
1	15165	1	160	373
2	13747	1	8	373
3	16583	1	111	373
4	17908	1	169	373
5	13065	1	74	373
6	17643	1	71	373
7	14237	1	38	373
8	12791	1	96	373
9	18074	1	190	373

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT
  CustomerID,
  ROUND(SUM(Quantity * UnitPrice), 0) AS user_total
FROM
  velvety-study-473605-t0.modulabs_project.data
GROUP BY
  CustomerID
HAVING
  SUM(Quantity * UnitPrice) > 0;
```

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기**

```
 CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_rfm AS
SELECT
 rf.CustomerID,
 rf.purchase_cnt,
 rf.item_cnt,
 rf.Recency,
 ut.user_total,
 ROUND(ut.user_total / rf.purchase_cnt, 2) AS user_average
FROM
 velvety-study-473605-t0.modulabs_project.user_rf AS rf
LEFT JOIN (
 SELECT
  CustomerID,
  ROUND(SUM(Quantity * UnitPrice), 0) AS user_total
 FROM
  velvety-study-473605-t0.modulabs_project.data
 GROUP BY
  CustomerID
 HAVING
  SUM(Quantity * UnitPrice) > 0
) AS ut
ON
 rf.CustomerID = ut.CustomerID;
```

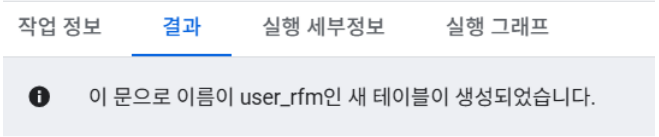

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
SELECT *
FROM velvety-study-473605-t0.modulabs_project.user_rfm
LIMIT 10;
```

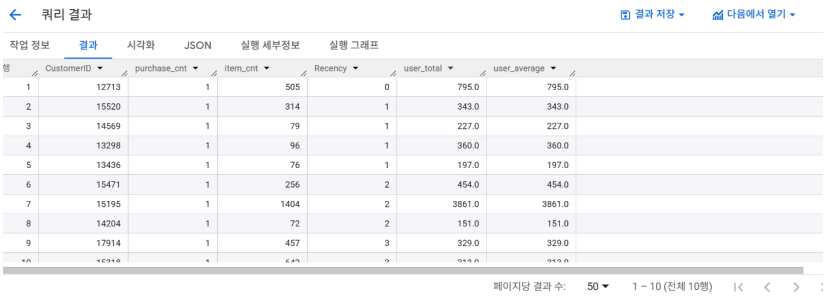

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` **테이블과 결과를 합치기**
  3) `user_data` **라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_data AS
WITH
  unique_products AS (
    SELECT
      CustomerID,
      COUNT(DISTINCT StockCode) AS unique_products
    FROM
      velvety-study-473605-t0.modulabs_project.data
    GROUP BY
      CustomerID
  )
SELECT
  ur.*,
  up.unique_products
FROM
  velvety-study-473605-t0.modulabs_project.user_rfm AS ur
JOIN
  unique_products AS up
  ON ur.CustomerID = up.CustomerID;

SELECT *
FROM velvety-study-473605-t0.modulabs_project.user_data
```

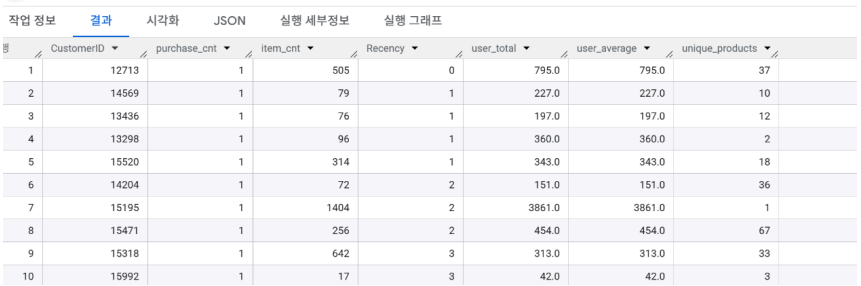

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_data AS
WITH
 purchase_intervals AS (
  SELECT
   CustomerID,
   COALESCE(ROUND(AVG(interval_days), 2), 0) AS average_interval
  FROM (
   SELECT
    CustomerID,
    DATE_DIFF(
     DATE(InvoiceDate),
     LAG(DATE(InvoiceDate)) OVER (PARTITION BY CustomerID ORDER BY DATE(InvoiceDate)),
     DAY
    ) AS interval_days
   FROM
    velvety-study-473605-t0.modulabs_project.data
  )
  GROUP BY
   CustomerID
 )

SELECT
 u.* EXCEPT (average_interval),
 pi.average_interval
FROM
 velvety-study-473605-t0.modulabs_project.user_data AS u
LEFT JOIN
 purchase_intervals AS pi
 ON u.CustomerID = pi.CustomerID;

SELECT *
FROM velvety-study-473605-t0.modulabs_project.user_data
```

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	CustomerID	purchase_cnt	item_cnt	Recency	user_total	user_average	unique_products	average_interval
1	16881	1	600	66	432.0	432.0	1	0.0
2	13302	1	5	155	64.0	64.0	1	0.0
3	16344	1	18	158	101.0	101.0	1	0.0
4	17763	1	12	263	15.0	15.0	1	0.0
5	16737	1	288	53	418.0	418.0	1	0.0
6	15195	1	1404	2	3861.0	3861.0	1	0.0
7	16990	1	100	218	179.0	179.0	1	0.0
8	13307	1	4	120	15.0	15.0	1	0.0
9	14424	1	48	17	322.0	322.0	1	0.0
10	13135	1	4300	196	3096.0	3096.0	1	0.0

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE velvety-study-473605-t0.modulabs_project.user_data AS
WITH
  TransactionInfo AS (
    SELECT
      CustomerID,
      COUNT(DISTINCT InvoiceNo) AS total_transactions,
      COUNT(
        DISTINCT CASE WHEN InvoiceNo LIKE 'C%' THEN InvoiceNo END
      ) AS cancel_frequency
    FROM
      velvety-study-473605-t0.modulabs_project.data
    GROUP BY
      CustomerID
  )
SELECT
  u.CustomerID,
  u.purchase_cnt,
  u.item_cnt,
  u.Recency,
  u.user_total,
  u.user_average,
  u.unique_products,
  u.average_interval,
  COALESCE(t.cancel_frequency, 0) AS cancel_frequency,
  COALESCE(
    ROUND((t.cancel_frequency / t.total_transactions) * 100, 2),
    0
  ) AS cancel_rate
FROM
  velvety-study-473605-t0.modulabs_project.user_data AS u
LEFT JOIN
  TransactionInfo AS t
  ON u.CustomerID = t.CustomerID;
```

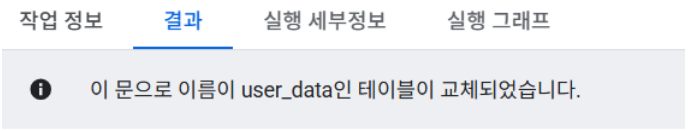

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
SELECT *
FROM velvety-study-473605-t0.modulabs_project.user_data
```

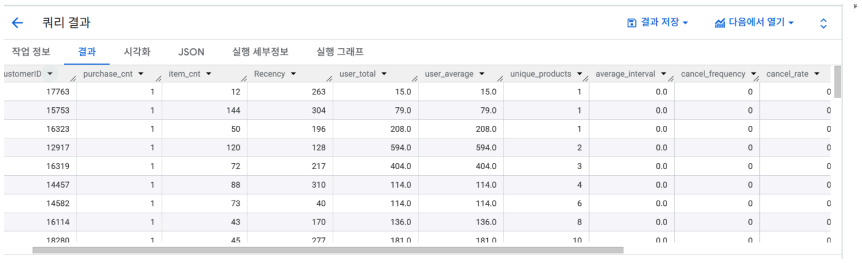

회고

Keep : 중간중간 잘 돌아가는지 확인하여서 오류가 생기면 그때그때 확인하고 고칠 수 있었던 점이 좋았습니다. 또한 흐름에 맞춰 코드 중간중간 구간을 표시하여 코드를 되돌아가야하는 때가 생겼을때 빠르게 다시 찾을 수 있었습니다. 그 점이 좋았습니다.

Problem :쿼리 결과에서 페이지를 넘길 수 있다는 사실을 몰라서
답지와 고객 수, recency값이 다르게 나온것처럼 보여(행이 순서대로 나오지 않는다는 점을 간과하였음) 원인을 찾는 데 많은 시간이 소요되었습니다..

Try : 다음 프로젝트에서는 분석 목표에 따른 데이터 정제 규칙을 먼저 명확히 정의하여, 정답지와의 결과 차이로 인한 혼란을 줄이겠습니다.

작업 정보 | 결과 | 시각화 | JSON | 실행 세부정보 | 실행 그래프

행	Segment	customer_count	avg_recency	avg_frequency	avg_monetary	avg_product_vari...	avg_purchase_int...	avg_cancel_rate
1	Loyal Customers (충성 고객)	974	31.8	4.5	1328.0	65.7	5.7	13.39
2	Hibernating (휴면 고객)	966	216.2	1.2	289.0	19.5	1.1	3.16
3	Champions (최우수 고객)	940	10.9	13.3	5855.0	136.2	2.5	15.45
4	At Risk (이탈 위험 고객)	420	167.2	3.1	472.0	31.2	6.1	17.83
5	Big Spenders (큰 손 고객)	390	126.6	4.1	2030.0	63.4	3.0	11.1
6	New Customers (신규 고객)	325	17.4	1.4	321.0	28.3	4.3	2.31
7	Potential Loyalists (잠재 충성 고...	319	51.0	1.2	324.0	27.7	1.1	2.04

인사이트
(최종으로 만든 user_data 테이블을 마지막으로 가공하여 등급을 생성함)

RFM 분석 결과 및 인사이트

1. 핵심 고객층이 전체 수익을 견인
분석 결과, 우리 비즈니스의 핵심 수익은 최우수 고객과 충성 고객그룹이 전체 고객의 약 38%를 차지하고있습니다
이는 소수의 핵심 고객에 대한 의존도가 높은 구조임을 보여주며, 이들의 충성도를 유지하고 강화하는 전략이 매우 중요해 보입니다.
따라서 해당 고객층에는 메리트를 부여하여 지속적인 최우수/충성 고객그룹이 되도록 유지해야합니다

2. 이탈 위험 고객의 재활성화 시급
과거에는 핵심 고객이었지만 현재는 이탈 조짐을 보이는 이탈 위험 고객 그룹을 식별했습니다.
이들의 과거 평균 구매 빈도와 구매액은 충성 고객 그룹과 비슷할 정도로 높았지만, 마지막 구매일로부터 평균 211일이나 지나 활동이 멈춘 상태였습니다.
이들은 비즈니스에 큰 손실이 될 수 있는 잃어버린 우량 고객이므로, 이들이 완전히 이탈하기 전에 조치가 필요합니다.

3. 신규 고객의 높은 초기 취소율 문제
이번 분석에서 주목할 만한 점 중 하나는 신규 고객그룹의 평균 취소율이 모든 그룹 중 가장 높게 나타났습니다.
이는 신규 고객이 우리 서비스의 첫 구매 과정에서 어려움을 겪거나 만족도가 낮을 수 있음을 시사합니다.